

# Python Pandas की समीक्षा


## सीबीएसई पाठ्यक्रम पर आधारित

### इनफोर्मेटिक्स प्रैविट्सेज कक्षा -12

अध्याय -1



द्वारा:  
संजीव भदौरिया  
र-नातकोत्तर शिक्षक (संगणक विज्ञान )  
के० वि० बाराबंकी (लखनऊ संभाग)



# Python Pandas ( एक नज़र)

- Data को analysis करने का एक अत्यंत महत्वपूर्ण हिस्सा होता है- Data Processing क्यों कि data हमेशा इच्छित format में नहीं होता है।
- Data को analysis करने से पहले बहुत सारी processing की ज़रूरत होती है जैसे - Cleaning, Restructuring या merging इत्यादि।
- Data को fast process करने के लिए python में बहुत सारे tools उपलब्ध हैं - जैसे - Numpy, Scipy, Cython और Pandas.
- Pandas को Numpy के ऊपर रखा गया है।
- इस ध्याय में हम Python Pandas Data Series और DataFrames के basic concepts सीखेंगे जिन्हें हमने कक्षा - 11 में भी सीखा था।

# Python Pandas

- Pandas एक open-source python की library है जो अपने powerful data-structure का प्रयोग करके data manipulation और उसको analysis करने की सुविधा प्रदान करती है।
- इनकी performance बहुत अच्छी होती है।
- Pandas विभिन्न प्रकार के data को process करने के लिए कई functions प्रदान करता है।
- Data analysis करते समय यह बहुत ध्यान रखना होता है कि आप सही data type को प्रयोग कर रहे हैं अन्यथा आपको कई errors का सामना करना पड़ सकता है। pandas के द्वारा निम्न data type पर आसानी से काम किया जा सकता है।

Pandas dtype	Python type	NumPy type	Usage
object	str	string_, unicode_	Text
int64	int	int_, int8, int16, int32, int64, uint8, uint16, uint32, uint64	Integer numbers
float64	float	float_, float16, float32, float64	Floating point numbers
bool	bool	bool_	True/False values
datetime64	NA	datetime64[ns]	Date and time values
timedelta[ns]	NA	NA	Differences between two datetimes
category	NA	NA	Finite list of text values

# Pandas Series

- Pandas की primary building block, *Series* ही होती है।
- *Series* एक labeled *One-Dimensional Array* होती है जो किसी भी data type को hold कर सकती है।
- Series का data हमेशा mutable होता है अर्थात् इनको बदला जा सकता है।
- लेकिन Series के data का size immutable होता है।
- यह एक प्रकार से 2 arrays का structure प्रतीत होता है जिसमें एक index होता है और दूसरे में actual values.
- Series में row labels को *index* कहा जाता है।
- निम्न उदहारण data types हैं जिनसे series बनाई जा सकती है और ऐसा करने के लिए *series()* का प्रयोग किया जाता है।

```
Num = [23, 54, 34, 44, 35, 66, 27, 88, 69, 54] # a list with homogeneous data
Emp = ['A V Raman', 35, 'Finance', 45670.00] # a list with heterogeneous data
Marks = {"ELENA JOSE" : 450, "PARAS GUPTA" : 467, "JOEFFIN JOSEPH" : 480} # a dictionary
Num1 = (23, 54, 34, 44, 35, 66, 27, 88, 69, 54) # a tuple with homogeneous data
Std = ('AKYHA KUMAR', 78.0, 79.0, 89.0, 88.0, 91.0) # a list with heterogeneous data
```

# Series Objects को बनाना

– एक series type object को कई तरीकों से बनाया जा सकता है।

1. Series ( ) फंक्शन का प्रयोग करके -

**<Series Object> = pandas.Series( )** यह empty series बनाएगा।

```
>>> import pandas as pd  
>>> ob = pd.Series()  
>>> ob  
Series([], dtype: float64)
```

2. Non-empty series बनाना –

Import pandas as pd

**<Series Object> = pd.Series(data, index=idx)** जहाँ data कोई भी python sequence, ndarray, python dictionary या scalar value हो सकता है।

```
>>> import pandas as pd  
>>> ob = pd.Series(range(5))  
>>> ob  
0    0  
1    1  
2    2  
3    3  
4    4  
dtype: int64
```

Index

```
>>> import pandas as pd  
>>> obj=pd.Series([3,5,4,4.5])  
>>> obj  
0    3.0  
1    5.0  
2    4.0  
3    4.5  
dtype: float64
```

# Series Objects को बनाना

## 1. Dictionary के साथ series बनाना

Index of Keys

```
>>> import pandas as pd  
>>> obj=pd.Series({'Jan':31,'Feb':28,'Mar':31})  
>>> obj  
Jan    31  
Feb    28  
Mar    31  
dtype: int64
```

## 2. Scalar value के साथ series बनाना -

```
>>> import pandas as pd  
>>> a=pd.Series(10,index=range(0,3))  
>>> a  
0    10  
1    10  
2    10  
dtype: int64
```

```
>>> import pandas as pd  
>>> b=pd.Series(15,index=range(1,6,2))  
>>> b  
1    15  
3    15  
5    15  
dtype: int64
```

```
>>> import pandas as pd  
>>> c=pd.Series('Welcome to BBK', index=['Hema','Rahul','Anup'])  
>>> c  
Hema    Welcome to BBK  
Rahul    Welcome to BBK  
Anup    Welcome to BBK  
dtype: object
```

# Series Object Attributes

3. कुछ common attributes निम्न हैं-

**<series object>. <AttributeName>**

Attribute	Description
Series.index	Returns index of the series
Series.values	Returns ndarray
Series.dtype	Returns dtype object of the underlying data
Series.shape	Returns tuple of the shape of underlying data
Series.nbytes	Return number of bytes of underlying data
Series.ndim	Returns the number of dimension
Series.size	Returns number of elements
Series.itemsize	Returns the size of the dtype
Series.hasnans	Returns true if there are any NaN
Series.empty	Returns true if series object is empty

# Series Object Attributes

```
>>> import pandas as pd
>>> s=pd.Series(range(1,15,3), index=[x for x in 'abcde'])
>>> s.index
Index(['a', 'b', 'c', 'd', 'e'], dtype='object')
>>> s.values
array([ 1,  4,  7, 10, 13], dtype=int64)
>>> s.shape
(5,)
>>> s.size
5
>>> s.nbytes
40
>>> s.ndim
1
>>> s.itemsize
```

# Series Object को access करना

```
>>> import pandas as pd  
>>> import numpy as np  
>>> a=np.arange(9,13)  
>>> ob=pd.Series(index=a, data=a**2)  
>>> ob  
9      81  
10     100  
11     121  
12     144  
dtype: int32  
>>> ob[10]  
100
```

ऑब्जेक्ट की values को print करना

Individual value को print करना

```
>>> ob[2:4]  
11    121  
12    144  
dtype: int32  
>>> ob[1:]  
10    100  
11    121  
12    144  
dtype: int32  
>>> ob[0::2]  
9     81  
11   121  
10   100  
9     81  
dtype: int32
```

Objects की slicing

```
>>> ob[::-1]  
12    144  
11    121  
10    100  
9     81  
dtype: int32
```

Objects की slicing करना बहुत आसान है बस निम्न syntax का अनुसरण करिए

*<objectName>[<start>:<stop>:<step >]*

# head() और tail () Function

1. head(<n> ) function शुरू से n elements return करता है यदि n न दे तो अपने आप शुरू के 5 record दिखायेगा |
2. tail(<n> ) function आखिरी से n elements return करता है यदि n न दे तो अपने आप आखिरी के 5 record दिखायेगा |

```
>>> import pandas as pd  
>>> import math  
>>> s=pd.Series(data=[math.sqrt(x) for x in range(1,10)],index=[x for x in range(1,10)])
```

```
>>> s  
1    1.000000  
2    1.414214  
3    1.732051  
4    2.000000  
5    2.236068  
6    2.449490  
7    2.645751  
8    2.828427  
9    3.000000  
dtype: float64
```

```
>>> s.head(6)  
1    1.000000  
2    1.414214  
3    1.732051  
4    2.000000  
5    2.236068  
6    2.449490  
dtype: float64
```

```
>>> s.tail(7)  
3    1.732051  
4    2.000000  
5    2.236068  
6    2.449490  
7    2.645751  
8    2.828427  
9    3.000000  
dtype: float64
```

```
>>> s.head()  
1    1.000000  
2    1.414214  
3    1.732051  
4    2.000000  
5    2.236068  
dtype: float64  
>>> s.tail()  
5    2.236068  
6    2.449490  
7    2.645751  
8    2.828427  
9    3.000000  
dtype: float64
```

# NumPy array और Series objects में अंतर

1. ndarray के case में आप तभी vector operation कर सकते हैं जब दोनों ndarray के shape सामान हों | जबकि series ऑब्जेक्ट के केस में अगर मैचिंग index के साथ ही align होगा अन्यथा NaN return होता है |

```
>>> import numpy as np
>>> a=np.array([1,2,3])
>>> b=np.array([1,2,3,45,5])
>>> a+b
Traceback (most recent call last):
  File "<pyshell#143>", line 1, in <module>
    a+b
ValueError: operands could not be broadcast together with shapes (3,) (5,)
```

2. ndarray में index हमेशा 0 से शुरू होता है और सदैव numeric ही होगा |लेकिन series में numbers के आलावा किसी भी type का index हो सकता है और ज़रूरी नहीं की index 0 से शुरू हो |

# DataFrame

- Pandas का मुख्य object **DataFrame** होता है | और यह pandas का सबसे अधिक प्रयोग किया जाने वाला Data Structure है |
- **DataFrame** एक **Two -Dimensional Array** होता है जो किसी भी data type को hold कर सकती है | और यह tabular format में data को store करता है |
- Finance, Statistics, Social Science और कई engineering branch में इसका प्रयोग अधिकता में किया जाता है |
- DataFrame में data और इसका size दोनों ही mutable होते हैं अर्थात् इन्हें बदला जा सकता है |
- DataFrame में दो विभिन्न indexes होते हैं - **row index** और **column index** |

A DataFrame with two-dimensional array with heterogeneous data.

Country	Population	BirthRate	UpdateDate
China	1,379,750,000	14.00	2016-08-11
India	1,330,780,000	21.76	2016-08-11
United States	324,882,000	13.82	2016-08-11
Indonesia	260,581,000	18.84	2016-01-07
Brazil	206,918,000	18.43	2016-08-11
Pakistan	194,754,000	27.62	2016-08-11

# DataFrame को बनाना और प्रदर्शित करना

- 2 D फॉर्मेट में डाटा को pass करके एक DataFrame object बनाया जा सकता है।

import pandas as pd

```
<dataFrameObject> = pd.DataFrame(<a 2D Data Structure>,\ [columns=<column sequence>],[index=<index sequence>])
```

- आप DataFrame को कई तरीके से data values pass करके बना सकते हैं जैसे –
  - 2D dictionaries
  - 2D ndarrays
  - Series type object
  - Another DataFrame object

# 2D Dictionary से DataFrame बनाना

## A. List या ndarrays की dictionary से DataFrame बनाना |

```
>>> import pandas as pd  
>>> dict={'Students':['Pratibha','Ritika','Saumya','Aryan','Keshwam','Priyanka'],  
,'Marks':[69,65,64,59,59,40], 'Sports':['TQ','TT','KB','VB','CR','KO']}  
>>> dtf=pd.DataFrame(dict)  
>>> dtf
```

	Students	Marks	Sports
0	Pratibha	69	TQ
1	Ritika	65	TT
2	Saumya	64	KB
3	Aryan	59	VB
4	Keshwam	59	CR
5	Priyanka	40	KO

उपरोक्त उदाहरण में index स्वतः 0 से 5 तक आगे तथा column के name स्वतः वाही आये जो dictionary में keys थीं।

np.range(n) का प्रयोग करके indexes स्वतः निर्मित हो गयीं।

2D Dictionary के keys column के नाम हो गए

```
>>> import pandas as pd  
>>> dict={'Students':['Pratibha','Ritika','Saumya','Aryan','Keshwam','Priyanka'],  
,'Marks':[69,65,64,59,59,40], 'Sports':['TQ','TT','KB','VB','CR','KO']}  
>>> dtf=pd.DataFrame(dict,index=['I','II','III','IV','V','VI'])  
>>> dtf
```

	Students	Marks	Sports
I	Pratibha	69	TQ
II	Ritika	65	TT
III	Saumya	64	KB
IV	Aryan	59	VB
V	Keshwam	59	CR
VI	Priyanka	40	KO



यहाँ indexes आपने  
specify किये हैं।

अर्थात् यदि आप index का sequence देते हैं तो index आपके द्वारा  
दिया गया ही set होगा अन्यथा वह स्वतः 0 से n-1 तक का index  
लेलेगा।

# 2D Dictionary से DataFrame बनाना

## B. Dictionaries की dictionary से DataFrame बनाना |

```
>>> yr2015={'Qtr1':40000, 'Qtr2':35000, 'Qtr3': 47000, 'Qtr4':45000}
>>> yr2016={'Qtr1':42000, 'Qtr2':37000, 'Qtr3': 49000, 'Qtr4':47000}
>>> yr2017={'Qtr1':43000, 'Qtr2':38000, 'Qtr3': 50000, 'Qtr4':48000}
>>> kvfee={2015:yr2015,2016:yr2016,2017:yr2017}
>>> dtFee=pd.DataFrame(kvfee)
>>> dtFee
   2015  2016  2017
Qtr1  40000  42000  43000
Qtr2  35000  37000  38000
Qtr3  47000  49000  50000
Qtr4  45000  47000  48000
```

यहाँ आप index और column name देख कर समझ सकते हैं कि कैसे assign हुए

यह 2D Dictionary है जो ऊपर की dictionaries से मिलकर बनी है।

DataFrame ऑब्जेक्ट create हो गया।

यदि यहाँ yr2015, yr2016 और yr2017 के keys अलग होते तो dataframe के rows और column ज्यादा बढ़ जाते और बिना match वाले row और column में NaN store हो जाता।

# 2D ndarray से DataFrame बनाना

```
>>> import pandas as pd  
>>> import numpy as np  
>>> narr=np.array([[1,2,3],[4,5,6]],np.int32)  
>>> narr.shape  
(2, 3)  
>>> dtf=pd.DataFrame(narr)  
>>> dtf  
0   1   2  
0   1   2   3  
1   4   5   6
```

इसमें column name और index स्वतः अगये।

```
>>> import pandas as pd  
>>> import numpy as np  
>>> narr=np.array([[1,2,3],[4,5,6]],np.int32)  
>>> dtf=pd.DataFrame(narr, columns=['One','Two','Three'])  
>>> dtf  
One   Two   Three  
0     1     2       3  
1     4     5       6
```

इसमें column name user ने दिए हैं।

```
>>> dtf=pd.DataFrame(narr, columns=['One','Two','Three'], index=['A','B'])  
>>> dtf  
One   Two   Three  
A     1     2       3  
B     4     5       6
```

इसमें column name तथा index दोनों user ने दिए हैं।

# Series Object की 2D Dictionary से DataFrame बनाना

```
>>> import pandas as pd  
>>> population=pd.Series([35,39,34,64],index=['Class12','Class11','Class10','Class9'])  
>>> AvgMarks=pd.Series([350,390,340,400],index=['Class12','Class11','Class10','Class9'])  
>>> dict={0:population,1:AvgMarks}  
>>> dtf=pd.DataFrame(dict)  
>>> dtf
```

	0	1
Class12	35	350
Class11	39	390
Class10	34	340
Class9	64	400

यह 2D Dictionary है जो ऊपर की Series से मिलकर बनी है।

DataFrame ऑब्जेक्ट create हो गया।

```
>>> dict={'Population':population,'AverageMarks':AvgMarks}  
>>> dtf=pd.DataFrame(dict)  
>>> dtf
```

	Population	AverageMarks
Class12	35	350
Class11	39	390
Class10	34	340
Class9	64	400

DataFrame ऑब्जेक्ट को इस प्रकार भी बनाया जा सकता है।

# दूसरे DataFrame ऑब्जेक्ट से DataFrame बनाना

```
>>> import pandas as pd  
>>> import numpy as np  
>>> narr=np.array([[1,2,3], [4,5,6]])  
>>> dtf=pd.DataFrame(narr,columns=['first','Second','Third'],index=['A','B'])  
>>> dtf  
first   Second   Third  
A        1        2        3  
B        4        5        6  
>>> dtf2=pd.DataFrame(dtf)  
>>> dtf2  
first   Second   Third  
A        1        2        3  
B        4        5        6
```

DataFrame ऑब्जेक्ट को दूसरे  
DataFrame ऑब्जेक्ट से बनाया गया है।

## DataFrame ऑब्जेक्ट को display करना।

```
>>> dtf  
first   Second   Third  
A        1        2        3  
B        4        5        6  
>>> dtf2=pd.DataFrame(dtf)  
>>> dtf2  
first   Second   Third  
A        1        2        3  
B        4        5        6
```

DataFrame ऑब्जेक्ट  
को display करने का  
syntax ये है।

# DataFrame Attributes

- जब आप एक DataFrame ऑब्जेक्ट बनाते हैं तो इससे सम्बंधित समस्त सूचना जैसे
  - size, इसका datatype इत्यादि , attributes के द्वारा प्राप्त किये जा सकते हैं ।

**<DataFrame Object>.<attribute name>**

- कुछ attributes निम्न हैं -

Attribute	Description
index	यह dataframe के index मतलब (row labels) को दिखता है ।
columns	यह dataframe के column labels को दिखता है ।
axes	यह दोनों axes अर्थात index और column को return करता है ।
dtypes	यह dataframe के अन्दर रखे डाटा का datatype return करता है।
size	ऑब्जेक्ट में उपस्थित elements की संख्या return करता है ।
shape	यह dataframe की dimention की tuple return करता है ।
values	यह dataframe का numpy रूप return करता है ।
empty	यह एक सूचक है की dataframe empty है या नहीं।
ndim	यह axes/array की dimention को return करता है ।
T	यह index और column को transpose कर देता है।

# DataFrame Attributes

```
>>> dtf.index  
Index(['A', 'B'], dtype='object')  
>>> dtf.columns  
Index(['first', 'Second', 'Third'], dtype='object')  
>>> dtf.axes  
[Index(['A', 'B'], dtype='object'), Index(['first', 'Second', 'Third'], dtype='object')]  
  
>>> dtf.dtypes  
first    int32  
Second   int32  
Third    int32  
dtype: object  
>>> dtf.size  
6  
>>> dtf.shape  
(2, 3)  
>>> dtf.ndim  
2
```

```
>>> dtf.empty  
False  
>>> dtf.count()  
first      2  
Second     2  
Third      2  
dtype: int64  
>>> dtf.T  
          A   B  
first    1   4  
Second   2   5  
Third    3   6
```

```
>>> dtf.values  
array([[1, 2, 3],  
       [4, 5, 6]])
```

# DataFrame से Selecting और Accessing

- Column को select करना

<DataFrame Object>[<column name>]

एक column  
को select  
करने के लिए

या <DataFrame Object>.<column name>

कई column को select करने के लिए

<DataFrame Object>[column name की list ]

```
>>> dtf.first
<bound method NDFrame.first of      first  Second  Third
A      1      2      3
B      4      5      6>
>>> dtf['Second']
A      2
B      5
Name: Second, dtype: int32
```

```
>>> dtf[['Second', 'first']]
      Second  first
A        2      1
B        5      4
```

कई column में हम क्रम बदल सकते हैं।

# DataFrame से subset को select करना

<DataFrameObject>.loc [<StartRow> : <EndRow>, <StartCol> : <EndCol>]

```
>>> dtf
```

	Population	Avg Income	Per Capita Income
Delhi	1001	45000	44.955045
Mumbai	2005	56000	27.930175
Chennai	30236	57000	1.885170
Kolkata	4662	46000	9.867010

```
>>> dtf.loc['Delhi',:]
```

Population	1001.000000
Avg Income	45000.000000
Per Capita Income	44.955045
Name: Delhi, dtype: float64	

```
>>> dtf.loc[:, 'Population':'Per Capita Income']
```

	Population	Avg Income	Per Capita Income
Delhi	1001	45000	44.955045
Mumbai	2005	56000	27.930175
Chennai	30236	57000	1.885170
Kolkata	4662	46000	9.867010

```
>>> dtf.loc['Mumbai':'Kolkata',:]
```

	Population	Avg Income	Per Capita Income
Mumbai	2005	56000	27.930175
Chennai	30236	57000	1.885170
Kolkata	4662	46000	9.867010

```
>>> dtf.loc['Delhi':'Mumbai', 'Population':'Avg Income']
```

	Population	Avg Income
Delhi	1001	45000
Mumbai	2005	56000

# DataFrame से subset को select करना

<DataFrameObject> .iloc [<Row Index> : <RowIndex>, <ColIndex> : <ColIndex>]

```
>>> dtf.iloc[0:2,1:3]
```

	Avg Income	Per Capita Income
Delhi	45000	44.955045
Mumbai	56000	27.930175

```
>>> dtf.iloc[0:2,1:2]
```

	Avg Income
Delhi	45000
Mumbai	56000

# DataFrame से Individual Value को select करना

<DFOBJECT>. <col name.[row name or row index]>

या

<DFOBJECT> . at [<row name>,<col name>]

या

<DFOBJECT> iat[<row index>, <col index>]

```
>>> dtf
```

	One	Two	Three
A	1	2	3
B	4	5	6

```
>>> dtf.Two['B']
```

```
5
```

```
>>> dtf.Two[0]
```

```
2
```

```
>>> dtf.at['A','Three']
```

```
3
```

```
>>> dtf.iat[1,2]
```

```
6
```

# DataFrame में values को access करना व् modify करना

a) नए column को change या add करने के लिए निम्न syntax का प्रयोग करें |

<DFObject>.<Col Name>[<row label>]=<new value>

```
>>> dtf
      One   Two   Three
A    1     2     3
B    4     5     6
C    7     8     9
>>> dtf['Four']=44
>>> dtf
      One   Two   Three   Four
A    1     2     3     44
B    4     5     6     44
C    7     8     9     44
```

चूंकि इसमें 'Four' नाम से कोई column नहीं है  
तो नया column add हो गया |

चूंकि इसमें 'Four' नाम से column है तो  
column के मानों में बदलाव हो गया |

```
>>> dtf['Four']=66
>>> dtf
      One   Two   Three   Four
A    1     2     3     66
B    4     5     6     66
C    7     8     9     66
```

# DataFrame में values को access करना व् modify करना

b) नए row को change या add करने के लिए निम्न syntax का प्रयोग करें |

<DFObject> at[<RowName>, : ] =<new value>

या

<DFObject> loc[<RowName>, : ] =<new value>

```
>>> dtf.at['D', :] = 88
>>> dtf
   One    Two    Three    Four
A    1.0    2.0    3.0   66.0
B    4.0    5.0    6.0   66.0
C    7.0    8.0    9.0   66.0
D   88.0   88.0   88.0   88.0
```

चूंकि इसमें 'D' नाम से कोई row नहीं थी तो  
नयी row add हो गयी |

```
>>> dtf.at['D', :] = 99
>>> dtf
   One    Two    Three    Four
A    1.0    2.0    3.0   66.0
B    4.0    5.0    6.0   66.0
C    7.0    8.0    9.0   66.0
D   99.0   99.0   99.0   99.0
```

चूंकि इसमें 'D' नाम से row नहीं तो row की  
values change हो गयी |

# DataFrame में values को access करना व् modify करना

c) Single value को change करने के लिए निम्न syntax का प्रयोग करें।

<DFObject>.<ColName>[<RowName/Label>]

```
>>> dtf
      One   Two   Three   Four
A    1.0   2.0   3.0   66.0
B    4.0   5.0   6.0   66.0
C    7.0   8.0   9.0   66.0
D   99.0  99.0  99.0  99.0
>>> dtf.Three['D']=100
>>> dtf
      One   Two   Three   Four
A    1.0   2.0   3.0   66.0
B    4.0   5.0   6.0   66.0
C    7.0   8.0   9.0   66.0
D   99.0  99.0  100.0  99.0
```

```
>>> dtf['Four']=[10,11,12,13]
>>> dtf.at['D']=[13,14,15,16]
>>> dtf
      One   Two   Three   Four
A    1.0   2.0   3.0   10
B    4.0   5.0   6.0   11
C    7.0   8.0   9.0   12
D   13.0  14.0  15.0  16
```

इसमें D वाले row में 'Three' वाले column में value बदल गयी।

Values को ऐसे भी change किया जा सकता है।  
जिसमें row या column के अलग अलग values  
भी दिए जा सकते हैं।

# DataFrame में values को access करना व् modify करना

Column को delete करने के लिए निम्न syntax का प्रयोग करें |

del <DFObject>[<ColName>] या

df.drop([<Col1Name>,<Col2Name>, . . ], axis=1)

```
>>> del dtf['Four']
```

```
>>> dtf  
      One   Two   Three
```

```
A    1.0   2.0   3.0  
B    4.0   5.0   6.0  
C    7.0   8.0   9.0  
D   13.0  14.0  15.0
```

```
>>> dtf.drop(['Two','Three'],axis=1)
```

```
      One  
A    1.0  
B    4.0  
C    7.0  
D   13.0
```

axis =1 यह बताता है की column को delete करना है

del कमांड delete करने के बाद value return नहीं करता है जबकि drop method delete करने के बाद तुरंत बची हुई dataframe को return करता है।

# DataFrame में Iteration

- कभी कभी हमें पूरे dataframe पर iteration करना पड़ता है ऐसे में अलग से values को access करने के लिए code लिखना और समस्यात्मक हो जाता है। इसलिए dataframe पर iteration करना आवश्यक हो जाता है जिसे हम निम्न तरीके से कर सकते हैं।
- <DFObject>.iterrows( ) यह dataframe को row-wise subsets में देखता है
- <DFObject>.iteritems( ) यह dataframe को column-wise subsets देखता है।

# pandas.iterrows () function का प्रयोग

The screenshot shows a Python IDE window with the following content:

```
iter.py - C:/Users/KVBBKServer/AppData/Local/Programs/Python/Python36/iter.py (3.6.5)
File Edit Format Run Options Window Help
import pandas as pd
disales={2015:{'Qtr1':34500,'Qtr2':56000,'Qtr3':47000,'Qtr4':49000},\
         2016:{'Qtr1':44500,'Qtr2':46100,'Qtr3':57000,'Qtr4':59000},\
         2017:{'Qtr1':54500,'Qtr2':51000,'Qtr3':47000,'Qtr4':58500}}
df1=pd.DataFrame(disales)
for (row, rowSeries) in df1.iterrows():
    print("RowIndex : ",row)
    print("Containing : ")
    print(rowSeries)
>>> df1
      2015  2016  2017
Qtr1  34500  44500  54500
Qtr2  56000  46100  51000
Qtr3  47000  57000  47000
Qtr4  49000  59000  58500
```

Annotations in the image:

- A red callout box points from the first section of code to the output on the right, containing the text: "ये df1 की values हैं जिसे एक एक करके ऐसे प्रोसेस किया गया है।"
- A blue callout box points from the second section of code to the output on the right, containing the text: "DataFrame बनने के बाद नीचे वाले code को try करिए।"
- Arrows point from the code snippets to their corresponding outputs.

Output on the right side:

```
RowIndex : Qtr1
Containing :
2015 34500
2016 44500
2017 54500
Name: Qtr1, dtype: int64
RowIndex : Qtr2
Containing :
2015 56000
2016 46100
2017 51000
Name: Qtr2, dtype: int64
RowIndex : Qtr3
Containing :
2015 47000
2016 57000
2017 47000
Name: Qtr3, dtype: int64
RowIndex : Qtr4
Containing :
2015 49000
2016 59000
2017 58500
Name: Qtr4, dtype: int64
```

Sanjiv Bhandariya, कॉ. वि० बारांकी

# pandas.iteritems() function का प्रयोग

```
import pandas as pd
disales={2015:{'Qtr1':34500,'Qtr2':56000,'Qtr3':47000,'Qtr4':49000},\
         2016:{'Qtr1':44500,'Qtr2':46100,'Qtr3':57000,'Qtr4':59000},\
         2017:{'Qtr1':54500,'Qtr2':51000,'Qtr3':47000,'Qtr4':58500}}
df1=pd.DataFrame(disales)
for (col,colSeries) in df1.iteritems():
    print("Column Index : ", col)
    print("Containing : ")
    print(colSeries)
```

```
>>> df1
      2015  2016  2017
Qtr1  34500  44500  54500
Qtr2  56000  46100  51000
Qtr3  47000  57000  47000
Qtr4  49000  59000  58500
```

ये df1 की values हैं जिसे एक एक करके ऐसे प्रोसेस किया गया है।

```
Column Index : 2015
Containing :
Qtr1  34500
Qtr2  56000
Qtr3  47000
Qtr4  49000
Name: 2015, dtype: int64
Column Index : 2016
Containing :
Qtr1  44500
Qtr2  46100
Qtr3  57000
Qtr4  59000
Name: 2016, dtype: int64
Column Index : 2017
Containing :
Qtr1  54500
Qtr2  51000
Qtr3  47000
Qtr4  58500
Name: 2017, dtype: int64
```

DataFrame बनने के बाद नीचे वाले code को try करिए।

```
df1=pd.DataFrame(disales)
for (col,colSeries) in df1.iteritems():
    print("Column Index : ", col)
    print("Containing : ")
    i=0
    for val in colSeries:
        print("At row",i," : ", val)
        i=i+1
```

# Program for iteration

- Write a program to iterate over a dataframe containing names and marks, then calculates grades as per marks (as per guideline below) and adds them to the grade column.

Marks  $\geq 90$       Grade A+

Marks 70 – 90      Grade A

Marks 60 – 70      Grade B

Marks 50 – 60      Grade C

Marks 40 – 50      Grade D

Marks  $< 40$       Grade F

# Program for iteration

```
import pandas as pd
import numpy as np
names=pd.Series(['Sanjeev', 'Rajeev', 'Sanjay', 'Abhay'])
marks=pd.Series([76, 86, 55, 54])
stud={'Name':names, 'Marks':marks}
df=pd.DataFrame(stud,columns=['Name', 'Marks'])
df['Grade']=np.NaN          #this will add NaN to all records of dataframe
print("Initial values in DataFrame")
print(df)
for (col,colSeries) in df.iteritems():
    length=len(colSeries)
    if col=='Marks':
        lstMrks=[]
        for row in range(length):
            mrks=colSeries[row]
            if mrks>=90:
                lstMrks.append('A+')
            elif mrks>=70:
                lstMrks.append('A')
            elif mrks>=60:
                lstMrks.append('B')
            elif mrks>=50:
                lstMrks.append('C')
            elif mrks>=40:
                lstMrks.append('D')
            else:
                lstMrks.append('F')
df['Grade']=lstMrks
print("\n\nDataFrame after calculation of Grades")
print(df)
```

Initial values in DataFrame

	Name	Marks	Grade
0	Sanjeev	76	NaN
1	Rajeev	86	NaN
2	Sanjay	55	NaN
3	Abhay	54	NaN

DataFrame after calculation of Grades

	Name	Marks	Grade
0	Sanjeev	76	A
1	Rajeev	86	A
2	Sanjay	55	C
3	Abhay	54	C

# कुछ अन्य ज़रूरी functions

DataFrame में कुछ ज़रूरी functions निम्न हैं-

<DF>.info ( )

<DF>.describe ( )

```
>>> df1
```

	A	B	C
0	1	2	3
1	4	5	6
2	7	8	9

```
>>> df2
```

	A	B	C
0	10	20	30
1	40	50	60
2	70	80	90

```
>>> df3
```

	A	B	C
0	100	200	300
1	400	500	600

```
>>> df4
```

	A	B
0	1000	2000
1	3000	4000
2	5000	6000

```
>>> df1.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3 entries, 0 to 2
Data columns (total 3 columns):
A    3 non-null int32
B    3 non-null int32
C    3 non-null int32
dtypes: int32(3)
memory usage: 116.0 bytes
```

```
>>> df1.describe()
```

	A	B	C
count	3.0	3.0	3.0
mean	4.0	5.0	6.0
std	3.0	3.0	3.0
min	1.0	2.0	3.0
25%	2.5	3.5	4.5
50%	4.0	5.0	6.0
75%	5.5	6.5	7.5
max	7.0	8.0	9.0

# कुछ अन्य ज़रूरी functions

DataFrame में कुछ ज़रूरी functions निम्न हैं-

<DF>.head ([ n=<n>] ) यहाँ n की default value 5 होती है |

<DF>.tail ( [n=<n>])

```
>>> df1
      A      B      C
0    1      2      3
1    4      5      6
2    7      8      9
3   10     20     30
4   40     50     60
5   70     80     90
6  100    200    300
7  400    500    600
8  700    800    900
```

```
>>> df1.head()
      A      B      C
0    1      2      3
1    4      5      6
2    7      8      9
3   10     20     30
4   40     50     60
>>> df1.tail()
      A      B      C
4   40     50     60
5   70     80     90
6  100    200    300
7  400    500    600
8  700    800    900
```

```
>>> df1.head(n=3)
      A      B      C
0    1      2      3
1    4      5      6
2    7      8      9
>>> df1.tail(n=4)
      A      B      C
5   70     80     90
6  100    200    300
7  400    500    600
8  700    800    900
```

# Cumulative Calculations Functions

DataFrame में cumulative sum के लिए निम्न फंक्शन है -

<DF>.cumsum([axis = None])      यहाँ axis argument वैकल्पिक है।

```
>>> df1
      A   B   C
0    1   2   3
1    4   5   6
2    7   8   9
```

```
>>> df1.cumsum()
      A   B   C
0    1   2   3
1    5   7   9
2   12  15  18
```

```
>>> df1.cumsum(axis='rows')
      A   B   C
0    1   2   3
1    5   7   9
2   12  15  18
```


```
>>> df1.cumsum(axis='columns')
      A   B   C
0    1   3   6
1    4   9  15
2   12  15  24
```

# Data Aggregation Functions

- Data analysis के लिए पाइथन एक बहुत अच्छी कंप्यूटर भाषा है।
- Python pandas इस प्रकार के data को analyze करने के लिए कई प्रकार के data aggregation function प्रदान करता है।
- Analysis का एक महत्वपूर्ण कार्य होता है बड़े dataset का summarization जिसे aggregations को compute करना कहते हैं जैसे- sum(), mean(), median(), min() और max() जिसमें विशाल dataset से एक संख्या मिल जाती है।
- इस अध्याय में हम इन्ही data aggregate functions का प्रयोग करना सीखेंगे।
- Aggregation का अर्थ होता है एक विशाल dataset की values को process करके एक value प्राप्त करना।
- Data aggregation में हमेशा multivalued functions दिए जाते हैं जो एक single value return करते हैं।
- दिया जाने वाला dataset या तो series या DataFrame होता है।

# Data Aggregation Functions

- हम निम्न excel sheet से एक dataframe बनाते हैं - जिसका process निम्न है।



The screenshot shows an Excel spreadsheet with data in columns A through F. Column A is labeled 'Student\_Name', column B is 'Age', column C is 'Gender', and columns D, E, and F are labeled 'Test1', 'Test2', and 'Test3' respectively. The data includes rows for Aryan (Age 16, Gender F), Pratibha (Age 16, Gender M), Saumya (Age 17, Gender F), Ritika (Age 15, Gender F), Hari (Age 16, Gender M), and Ram (Age 14, Gender F). Some cells contain 'NaN' values.

	A	B	C	D	E	F
1	Student_Name	Age	Gender	Test1	Test2	Test3
2	Aryan	16	F	7.6	8	7.6
3	NaN	NaN	NaN	NaN	NaN	NaN
4	Pratibha	16	M	8.6	NaN	NaN
5	Saumya	17	F	6.5	7.9	8.8
6	Ritika	15	F	6.8	7.7	7.9
7	Hari	16	M	9.2	9	NaN
8	Ram	14	F	6.8	8.7	8.8

```
>>> import pandas as pd  
>>> df=pd.read_csv("C:\\\\Users\\\\KVBBKServer\\\\Desktop\\\\Student.csv")  
>>> df
```

```
   Student_Name    Age  Gender  Test1  Test2  Test3  
0      Aryan  16.0      F    7.6    8.0    7.6  
1        NaN   NaN     NaN    NaN    NaN    NaN  
2    Pratibha  16.0      M    8.6    NaN    NaN  
3    Saumya  17.0      F    6.5    7.9    8.8  
4    Ritika  15.0      F    6.8    7.7    7.9  
5      Hari  16.0      M    9.2    9.0    NaN  
6       Ram  14.0      F    6.8    8.7    8.8
```

# Data Aggregation Functions

DataFrame “df” में प्रत्येक column में प्रत्येक row के लिए उपस्थित non-NaN items को गिनकर प्रदर्शित करना।

```
>>> df.count()  
Student_Name      6  
Age               6  
Gender            6  
Test1             6  
Test2             5  
Test3             4  
dtype: int64
```

उपरोक्त उदहारण में आपने देखा की प्रत्येक column में बिना NaN वाली values को ही गिना गया है।

DataFrame “df” में से किसी एक column के लिए उपस्थित non-NaN items को गिनकर प्रदर्शित करना हो तो निम्न दो तरीकों में से कोई भी तरीका अपना सकते हैं।

```
>>> df.Age.count()  
6  
>>> df['Age'].count()  
6  
>>> df.Test3.count()  
4  
>>> df['Test3'].count()  
4
```

DataFrame के column सभी non-NaN values को जोड़ने के लिए निम्न तरीका अपनाया जा सकता है।

```
>>> df.sum()  
Age          94.0  
Test1        45.5  
Test2        41.3  
Test3        33.1  
dtype: float64
```

DataFrame के row के सभी non-NaN values को जोड़ने के लिए निम्न तरीका अपनाया जा सकता है।

```
>>> df.sum(axis=1)  
0    39.2  
1     0.0  
2    24.6  
3    40.2  
4    37.4  
5    34.2  
6    38.3
```

# Data Aggregation Functions

```
>>> S=pd.Series([5,10,15,20,25])
```

```
>>> S.count()
```

```
5
```

```
>>> S.sum()
```

```
75
```

```
>>> S.mean()
```

```
15.0
```

```
>>> S.median()
```

```
15.0
```

```
>>> S.max()
```

```
25
```

```
>>> S.min()
```

```
5
```

```
>>> S.std()
```

```
7.905694150420948
```

```
>>> S.var()
```

```
62.5
```

```
>>> S=pd.Series([5,10,15,10,10,10,25])
```

```
>>> S.mode()
```

```
0    10
```

```
dtype: int64
```

Aggregation	Description
count()	कुल items की संख्या
sum()	दिए गए संख्याओं के सेट के items का sum को हल करता है।
mean()	दिए गए संख्याओं के सेट के items का mean या average को हल करता है।
median()	दिए गए संख्याओं के सेट के items के बीच की संख्या या median को हल करता है।
mode()	दिए गए संख्याओं के सेट के items में सबसे ज्यादा repeated value या mode को हल करता है।
max()	दिए गए संख्याओं के सेट में से सबसे बड़ी संख्या को खोजता है।
min()	दिए गए संख्याओं के सेट में से सबसे छोटी संख्या को खोजता है।
std()	दिए गए संख्याओं के सेट के items का standard deviation calculate करता है।
var()	दिए गए संख्याओं के सेट के items का variance calculate करता है।

# Data Aggregation Functions

```
>>> df.min()  
Age      14.0  
Test1    6.5  
Test2    7.7  
Test3    7.6  
dtype: float64  
>>> df.Age.min()  
14.0  
>>> df.Age.std()  
1.0327955589886446  
>>> df.var()  
Age      1.066667  
Test1    1.209667  
Test2    0.313000  
Test3    0.382500  
dtype: float64  
>>> df.Age.var()  
1.0666666666666669
```

## Assignment:

State wise sales values of an item is given below-

State	Sales
Goa	650000
Delhi	692400
Odisha	750000
Haryana	867000
Bihar	920000
Kerala	939000
Tamil Nadu	1015000
West Bengal	1553000
Maharashtra	2176000

Write Commands for the following (Dataframe name is dfA)

- Count the number of observation in dfA.
- Count the number of observation in column state of dfA.
- Sum of the non-null value across the row axis for dfA.
- Calculate the mean of Sales columns in dfA.
- Add a commission column into dfA. (Commission = sales\*0.04)
- Calculate the mean of all numeric columns in dfA.
- Calculate the mean of sales column.
- Find maximum sales and commission values.
- Find minimum sales and commission values.
- Find the standard deviation of commissions.

# Quantiles with Pandas

- Statistics में 3 शब्द बहुत प्रयोग में लाये जाते हैं - Quartile, Quantile और percentile. इनमें निम्न अंतर होता है |
  - 0 quartile = 0 quantile = 0 percentile
  - 1 quartile = 0.25 quantile = 25 percentile
  - 2 quartile = 0.50 quantile = 50 percentile
  - 3 quartile = 0.75 quantile = 75 percentile
  - 4 quartile = 1 quantile = 100 percentile
- Statistics में **Quartile** आपके data को 4 हिस्सों (quarter) में बाँट देता है |
- **Percentile** एक संख्या है, जहां एक निश्चित percentage स्कोर, उस संख्या से नीचे आता है | इनका प्रयोग अधिकतर परीक्षा इत्यादि में स्कोर को रिपोर्ट करने में किया जाता है |
  - Percentile =  $((N-\text{your Rank})/N)*100$
  - Your rank =  $(\text{percentile}/100) * \text{number of items}$
- Quantiles एक distribution में वह point हैं जो उस distribution में values के rank order से संबंधित हैं |

# Pandas में Quantile () का प्रयोग

- Pandas का quantile() function किसी request किये गए axis के लिए float अथवा series values को return करता है | request किया गया axis एक numpy percentile होता है | यह एक probabilities की list होती है जिस पर quantile compute किया जाना है |
  - माना यदि percentile = 25 है तो यह पहला quartile अथवा lower quartile होगा |
  - यदि percentile = 50 है तो यह दूसरा quartile अथवा median होगा |
  - यदि percentile = 75 है तो यह तीसरा quartile अथवा upper quartile होगा |
- इसका syntax निम्न है –  
*DataFrame.quantile(q=0.5, axis=0, numeric\_only=True, interpolation = 'linear')*
- जहाँ -
  - q एक float है या array के जैसा, इसका default 0.5 (50% quantile) और  $0 \leq q \leq 1$
  - axis : 0 अथवा ‘index’ और 1 अथवा ‘columns’ | इसका default 0 होता है |
  - numeric\_only : boolean, default True होता है |
  - interpolation: {‘linear’, ‘lower’, ‘higher’, ‘midpoint’, ‘nearest’}. यह वैकल्पिक (optional) होता है |

# Pandas में Quantile () का प्रयोग

Find the Quantile of an odd series s given bellow:

```
>>> s=pd.Series([15,16,18,27,29,32,36])  
>>> s.quantile(.25)  
17.0  
>>> s.quantile([0.25,0.5,0.75])  
0.25    17.0  
0.50    27.0  
0.75    30.5  
dtype: float64
```

आप निम्न कमांड भी try कर सकते हैं।

```
>>> import numpy as np  
>>> S=pd.Series([15,16,18,27,29,32,36])  
>>> np.percentile(S,25)  
17.0
```

Find the Quantile of an even series s given bellow:

```
>>> P=pd.Series([15,16,18,29,32,36])  
>>> P.quantile([.25,.5,.75])  
0.25    16.50  
0.50    23.50  
0.75    31.25  
dtype: float64
```

आप निम्न कमांड भी try कर सकते हैं।

```
>>> import numpy as np  
>>> S=pd.Series([15,16,18,29,32,36])  
>>> print(np.percentile(P,[25,50,75]))  
[16.5 23.5 31.25]
```

# Pandas में Quantile () का प्रयोग

Find the quantile of DataFrame “df”

```
>>> import pandas as pd
>>> df=pd.read_csv("C:\\\\Users\\\\KVBBKServer\\\\Desktop\\\\Student.csv")
>>> df
   Student_Name    Age  Gender  Test1  Test2  Test3
0      Aryan     16.0      F     7.6     8.0     7.6
1        NaN      NaN     NaN     NaN     NaN     NaN
2    Pratibha     16.0      M     8.6     NaN     NaN
3    Saumya     17.0      F     6.5     7.9     8.8
4    Ritika     15.0      F     6.8     7.7     7.9
5      Hari     16.0      M     9.2     9.0     NaN
6       Ram     14.0      F     6.8     8.7     8.8
>>> df.quantile(.25)
Age      15.250
Test1     6.800
Test2     7.900
Test3     7.825
Name: 0.25, dtype: float64
>>> df.quantile([.25,.5,.75])
    Age  Test1  Test2  Test3
0.25  15.25   6.80   7.9   7.825
0.50  16.00   7.20   8.0   8.350
0.75  16.00   8.35   8.7   8.800
>>> quants=[0.05,0.25,0.5,0.75,0.95]
>>> q=df.quantile(quants)
>>> print(q)
          Age  Test1  Test2  Test3
0.05  14.25  6.575   7.74  7.645
0.25  15.25  6.800   7.90  7.825
0.50  16.00  7.200   8.00  8.350
0.75  16.00  8.350   8.70  8.800
0.95  16.75  9.050   8.94  8.800
```

# Descriptive Statistics

- Python – pandas में descriptive या summary statistics के लिए *describe()* function का प्रयोग किया जाता है।
- *Describe()* के द्वारा mean, std और interquartile (IQR) values को हासिल किया जा सकता है।
- *Describe()* एक numeric columns पर काम करने के लिए बहुत ही आसन function होता है।
- किसी column के basic statistics को देखे के लिए आप *describe()* function का प्रयोग कर सकते हैं –जैसे - mean, min, max इत्यादि।
- सामान्यतया *describe()* character columns को छोड़ देता है और सिर्फ numeric columns पर कार्य करता है।
- किसी dataframe को *describe* करने पर सिर्फ numeric fields ही return होती है। और यह 8 प्रकार की statistical properties को दर्शाता है -

count()	mean()
std()	min()
25 <sup>th</sup> percentile	50 <sup>th</sup> percentile
75 <sup>th</sup> percentile	max()

# Descriptive Statistics

- Describe ( ) function का syntax निम्नवत है -

*DataFrame.describe(percentile = None, include = None, exclude=None)*

जहाँ :-

- percentile : default है [0.25, 0.5, 0.75 ]
- Include: default None है, अन्य में 'All' होसकता है।
- Exclude : भी default None है , यह तब प्रयोग में लाया जाता है जब आप किसी भी column को इन्क्लुड़े न करना चाहें।

```
>>> S=pd.Series([5,10,15,20,25])
>>> S.describe()
count      5.000000
mean      15.000000
std       7.905694
min      5.000000
25%     10.000000
50%     15.000000
75%     20.000000
max     25.000000
dtype: float64
```

STRING टाइप के series के  
लिए |

```
>>> str=pd.Series(['a','a','b','b','c','d'])
>>> str.describe()
count      6
unique      4
top        a
freq       2
dtype: object
```

# Descriptive Statistics

```
>>> import pandas as pd  
>>> df=pd.read_csv("C:\\\\Users\\\\KVBBKServer\\\\Desktop\\\\Student.csv")  
>>> df  
Student_Name    Age  Gender  Test1  Test2  Test3  
0      Aryan  16.0      F    7.6    8.0    7.6  
1        NaN   NaN     NaN    NaN    NaN    NaN  
2    Pratibha  16.0      M    8.6    NaN    NaN  
3     Saumya  17.0      F    6.5    7.9    8.8  
4     Ritika  15.0      F    6.8    7.7    7.9  
5       Hari  16.0      M    9.2    9.0    NaN  
6       Ram  14.0      F    6.8    8.7    8.8  
>>> df.describe()
```

	Age	Test1	Test2	Test3
count	6.000000	6.000000	5.000000	4.000000
mean	15.666667	7.583333	8.260000	8.275000
std	1.032796	1.099848	0.559464	0.618466
min	14.000000	6.500000	7.700000	7.600000
25%	15.250000	6.800000	7.900000	7.825000
50%	16.000000	7.200000	8.000000	8.350000
75%	16.000000	8.350000	8.700000	8.800000
max	17.000000	9.200000	9.000000	8.800000

DataFrame के लिए  
describe( ) function.

```
>>> df['Age'].describe()  
count      6.000000  
mean      15.666667  
std       1.032796  
min      14.000000  
25%      15.250000  
50%      16.000000  
75%      16.000000  
max      17.000000  
Name: Age, dtype: float64
```

# Descriptive Statistics (Assignment)

Example A dataframe dfS is given with following data for 10 students:

	Name	Total Marks
0	Amit Kumar	450
1	Vinamr Katyal	476
2	Aasha Goel	426
3	Naina Rawat	476
4	Dawn Sebastian	458
5	Riya Mary	446
6	Aashna Sharma	461
7	Piush Cocher	464
8	Om Berma	476
9	Manali Sovani	452

Write commands for the following:

- Find the default quantile of the DataFrame.
- Find the [.25, .5, .75] quantiles of the DataFrame.
- Write the summary of statistics pertaining to the dataframe column.
- Get the full summary of statistics to the dataframe.
- Find the 50th percentile of the dataframe.

# Histogram

- Histogram किसी data के distribution को analyze करने के लिए एक powerful टूल है।
- एक histogram plot को सामान्यतया किसी संख्या की frequency को दर्शाने के लिए प्रयोग किया जाता है।
- इसके द्वारा user को data का विभिन्न catagory में distribution आसानी से समझ में आजाता है। तथा साथ ही data की median और range भी समझ आजाती है।
- Histogram बनाने के लिए, पहले, हम values की पूरी range को intervals की एक series में विभाजित करते हैं। और दूसरा, हम गिनते हैं कि प्रत्येक interval में कितने values आते हैं।
- Matplotlib फिर bins में उन categories या intervals को call करता है। bins, variables के continuous और non-overlapping intervals होते हैं। वे एक दूसरे के ठीक लगे हुए (adjacent) और बराबर size के होने चाहिए।
- Histogram में -
  - **X – axis:** observation के intervals को दर्शाता है।
  - **Y- axis:** यह frequency के घनत्व (density) को दर्शाता है।

# Matplotlib

- Matplotlib पाइथन की एक अग्रणी visualization library है जो कि एक powerful और two dimensional plotting library है।
- यह numpy arrays के आधार पर बनी हुई एक multi-platform data visualization library है।
- यह सभी प्रकार के graph, plots, charts, histograms इत्यादि बनाने में सक्षम है।
- इसके लिए आपको अपने system में pip कमांड के द्वारा matplotlib library को install करना होता है।

A screenshot of a terminal window titled "pip install matplotlib". The command "pip install matplotlib" is entered. Below it, the path "C:\Users\KUBBKServer\AppData\Local\Programs\Python\Python36\Scripts>" is visible. A red callout box points to the Python session below, which shows the import statement and the printed version number.

```
pip install matplotlib
C:\Users\KUBBKServer\AppData\Local\Programs\Python\Python36\Scripts>pip install matplotlib
>>> import matplotlib
>>> print(matplotlib.__version__)
3.0.1
```

इस कमांड से हम पता कर सकते हैं कि matplotlib का कौन सा version installed है।

# Histogram बनाना

- Histogram बनाने के लिए syntax निम्न है -

```
DataFrame.hist(column=None, by=None, grid=True, xlabelsize=None, xrot=None, ylabelsize=None,  
yrot=None, ax=None, sharex=False, sharey=False, figsize=None, layout=None, bins=10, **kwds)
```

- column: is the dataframe column name to create a histogram.
- by: If passed, then used to form histograms for separate groups. The by option will take an object by which the data can be grouped.
- grid: takes a Boolean value, i.e., to enable (if **True**) or disable (if **False**) the grid.
- xlabelsize, ylabelsize: these options change the size of x and y label text size.
- sharex, sharey: to set both of the axes to the same range and scale.
- bin: isumber of histogram bins to be used. The default value is 10.
- fill: to fillis the dataframe column name to create a histogram.

- Example के लिए हम निम्न DataFrame लेते हैं -

```
>>> df
```

	Student_Name	Age	Gender	Test1	Test2	Test3
0	Aryan	16.0	F	7.6	8.0	7.6
1	NaN	NaN	NaN	NaN	NaN	NaN
2	Pratibha	16.0	M	8.6	NaN	NaN
3	Saumya	17.0	F	6.5	7.9	8.8
4	Ritika	15.0	F	6.8	7.7	7.9
5	Hari	16.0	M	9.2	9.0	NaN
6	Ram	14.0	F	6.8	8.7	8.8

# Histogram बनाना


```
>>> import matplotlib.pyplot as plt  
>>> df.hist()
```

Histogram बनाने के लिए hist( ) function का प्रयोग करते हैं।

```
array([[<matplotlib.axes._subplots.AxesSubplot object at 0x0000009B7FCB0080>,  
       <matplotlib.axes._subplots.AxesSubplot object at 0x0000009B7FD1A7F0>],  
      [<matplotlib.axes._subplots.AxesSubplot object at 0x0000009B7FE83D68>,  
       <matplotlib.axes._subplots.AxesSubplot object at 0x0000009B7FEB3320>]],  
     dtype=object)
```

```
>>> plt.show()
```

उपरोक्त कमांड चलाने पर बगल में दर्शाई गयी छवि जो histogram बन कर आरहा है वही output आपको प्रदर्शित होता है।




# Pandas dataframe से single Histogram बनाना

hist ( ) function में column pass कर देते हैं |

```
>>> df.hist(column='Age') ←  
array([[<matplotlib.axes._subplots.AxesSubplot object at 0x0000009B7FBB2630>]],  
      dtype=object)  
>>> plt.show()
```

उपरोक्त कमांड चलाने पर  
बगल में दर्शाई गयी छवि जो  
histogram बन कर आरहा है  
वही output आपको प्रदर्शित  
होता है।




# Histogram के bins के आकार को बदलना

```
>>> df.hist(column='Age', bins=5)  
array([[<matplotlib.axes._subplot  
      dtype=object)  
>>> plt.show()
```

hist ( ) function में column के साथ bins को भी pass कर देते हैं।

उपरोक्त कमांड चलाने पर बगल में दर्शाई गयी छवि जो histogram बन कर आरहा है वही output आपको प्रदर्शित होता है।




# Multiple pandas Histogram

```
>>> df.hist(column=["Test1", "Test2"])
array([[[<matplotlib.axes._subplots.AxesSubplot object at 0x00000000>,
         <matplotlib.axes._subplots.AxesSubplot object at 0x00000001>],
        dtype=object)]
>>> plt.show()
```



hist ( ) function में column को भी pass कर देते हैं।

उपरोक्त कमांड चलाने पर बगल में दर्शाई गयी छवि जो histogram बन कर आरहा है वही output आपको प्रदर्शित होता है।





# Histogram Axes को बदलना

```
>>> df.hist(column=["Test1", "Test2"], sharex=True) # Share only x axis  
>>> plt.show()
```




# Histogram Axes को बदलना

```
>>> df.hist(column=["Test1", "Test2"], sharex=True, sharey=True) # Share x and y axis  
>>> plt.show()
```




# Multiple features in one plot

```
>>> df[["Test1", "Test2", "Test3"]].plot.hist() # Note slicing is performed on df itself  
>>> plt.show()
```



# Multiple features in one plot


```
>>> df[["Test1", "Test2", "Test3"]].plot.hist(alpha=0.4) # Plot at 40% opacity  
>>> plt.show()
```



# Plotting DataFrame Columns using DataFrame plot () Method


```
>>> df.plot(kind='hist')
```

```
>>> plt.show()
```



# Histogram using single/multiple column

```
>>> df[['Age']].plot(kind='hist',bins=[0,5,10,15,20, 25],rwidth=0.8)  
>>> plt.show()
```



# Assignment

**Example** Using previous dataframe dfS, write the command to create following histograms:

- (a) Create a histogram plot to show Total Marks
- (b) Create a histogram plot to show Total Marks with bins 100.
- (c) Create a histogram plot to show Total Marks with bins [400,420,440,460,480,500].

**Solution** For data: dfA = pd.read\_csv('E:/IPSource\_XII/IPXIIChap03/Std7.csv')

Assume that the following modules are imported.

```
import pandas as pd
```

```
import matplotlib.pyplot as plt
```

```
(a) dfA = dfA.sort_values(by='Total Marks')  
    plt.show()
```

```
(b) dfA.hist(column="Total Marks", bins=200)  
    plt.show()
```

```
(c) dfA.hist(column="Total Marks", bins=[400,420,440,460,480,500])  
    plt.show()
```

Or

```
dfA[['Total Marks']].plot(kind='hist',bins=[400,420,440,460,480,500])  
plt.show()
```


# Function Application

- Pandas library कई सुविधाजनक function प्रदान करती है जो data science से सम्बंधित कई कार्यों को करने में सहायता करते हैं। functions के ऐसे कार्यों को function application कहते हैं।
- एक तरह से यह भी कह सकते हिं की functions को dataframe के साथ कई तरीकों से प्रयोग किये जाने को function application कह सकते हैं - जैसे -
  - सम्पूर्ण dataframe पर
  - Row wise अथवा column-wise
  - किसी individual value पर अर्थात element – wise
- इस क्रम में तीन प्रकार के function होते हैं -
  - pipe ( ) → dataframe wise function application
  - apply ( ) → row-wise/column-wise function application
  - applymap ( ) → element-wise function application

# pipe ( ) function

- कई बार हमें ऐसे काम करना पड़ता है कि एक function का output दूसरे function के लिए इनपुट का काम करेगा और तब process आगे बढ़ेगी | इसे ही pipe करना कहते हैं | निम्न उदहारण को देखें -

```
>>> math.pow(math.sqrt(25), 3)  
125.0
```



- इस उदहारण में पहले sqrt ( ) function का output आयेगा जो कि pow ( ) function के लिए इनपुट का काम करेगा | अर्थात् ये function, pipe में काम कर रहे हैं |
- pipe ( ) function सारे functions के आर्डर को बदल कर उस क्रम में लाता है जिस क्रम में वह execute हो रहे हैं |

```
df.add(div(power(sqrt(n), 2), 3), 100)  
df.pipe(sqrt, n).pipe(power, 2).pipe(div, 3).pipe(add, 100)
```

pipe function के अन्दर pass किये गए Function के साथ parenthesis नहीं देते हैं |

# pipe ( ) function

```
>>> df5.pipe(np.multiply, 2).pipe(np.add, 100)
```

	A	B	C
0	102	104	106
1	108	110	112
2	114	116	118
3	120	140	160
4	180	200	220
5	240	260	280
6	300	500	700
7	900	1100	1300
8	1500	1700	1900

```
>>> df5
```

	A	B	C
0	1	2	3
1	4	5	6
2	7	8	9
3	10	20	30
4	40	50	60
5	70	80	90
6	100	200	300
7	400	500	600
8	700	800	900

# apply ( ) और applymap ( )function

```
>>> df5
      A      B      C
0    1      2      3
1    4      5      6
2    7      8      9
3   10     20     30
4   40     50     60
5   70     80     90
6  100    200    300
7  400    500    600
8  700    800    900
```

जबकि यहाँ single value प्रति element return हो रही है | क्यों कि applymap ( ) एक element का function है |

```
>>> df5.apply(np.mean)
A      148.0
B      185.0
C      222.0
dtype: float64
>>> df5.applymap(np.mean)
      A      B      C
0    1.0    2.0    3.0
1    4.0    5.0    6.0
2    7.0    8.0    9.0
3   10.0   20.0   30.0
4   40.0   50.0   60.0
5   70.0   80.0   90.0
6  100.0  200.0  300.0
7  400.0  500.0  600.0
8  700.0  800.0  900.0
```

यहाँ single value प्रति column return हो रही है | क्योंकि apply( ) एक series का function है

# Missing Data को handle करना

- वह values जो किसी computation में हिस्सा नहीं ले पाती हैं या यों कहे कि missing values वह values होती हैं जिनका कोई computational significance नहीं होता है।
- Missing data को handle करने के लिए निम्न तरीके अपनाये जाते हैं -
  - Dropping missing data
  - Filling missing data (Imputation)

```
>>> df10
      A      B      C
0  1001  2002   NaN
1  3004  4005   NaN
2  5007  6008   NaN
...
```

```
>>> df11=df10.fillna(0)
      A      B      C
0  1001  2002  0.0
1  3004  4005  0.0
2  5007  6008  0.0
...
```

```
>>> df11=df10.dropna()
>>> df11
Empty DataFrame
Columns: [A, B, C]
Index: []
>>> df11=df10.dropna(how='all')
>>> df11
      A      B      C
0  1001  2002   NaN
1  3004  4005   NaN
2  5007  6008   NaN
```

# Comparison of Pandas Objects

```
>>> df1
```

	A	B	C
0	1	2	3
1	4	5	6
2	7	8	9

```
>>> df2
```

	A	B	C
0	10	20	30
1	40	50	60
2	70	80	90

```
>>> df3
```

	A	B	C
0	100	200	300
1	400	500	600

```
>>> df12
```

	A	B	C
0	101.0	202.0	303.0
1	404.0	505.0	606.0
2	NaN	NaN	NaN

```
>>> df1+df2==df1.add(df2)
```

	A	B	C
0	True	True	True
1	True	True	True
2	True	True	True

```
>>> df1+df3==df1.add(df3)
```

	A	B	C
0	True	True	True
1	True	True	True
2	False	False	False

```
>>> df1>5
```

	A	B	C
0	False	False	False
1	False	False	True
2	True	True	True

```
>>> (df1+df3).equals(df1.add(df3))
```

```
True
```

equals() दोनों ऑब्जेक्ट की  
बराबरी check करता है।

# Pivoting DataFrame

- *Data analysis* के लिए Pandas एक प्रचलित library है।
- किसी भी data analyst के लिए प्रमुख कार्यों में से एक डेटा टेबल को *pivot* करना है। अर्थात् table data को एक धुरी प्रदान करना जिसके आधार पर database काम करे।
- Pandas का प्रयोग करके MS-Excel के प्रकार के pivot tables बनाये जा सकते हैं।
- ये बड़े data को तुरंत *summarize* करके meaningful reports तैयार करने में आपके समय की बहुत बचत करते हैं।
- Pivot table हमें एक बड़े, विस्तृत डेटा सेट से महत्वपूर्ण record निकालने की अनुमति देती है।
- Pivot tables स्वतः sort, count, total इत्यादि कर लेती हैं।
- एक सामान्य बात कहें तो pivot करने का अर्थ है किसी index या column से unique value को प्रयोग करना और DataFrame बनाना।
- Pandas के द्वारा pivot table बनाने के लिए हम *pivot()* या *pivot\_table()* method का प्रयोग करते हैं।

# pivot( ) method का प्रयोग करके Pivoting करना

- pivot() method, column values के आधार पर data को reshape करके नया DataFrame बनाता है।
- यह method 3 arguments लेता है - *index, columns* और *values* | इनमें से 2 को लेना अनिवार्य है।
- इन arguments की value के रूप में आपको original table के column नाम देने होते हैं।
- तब pivot ( ) एक नयी table बनाता है जिनके row और column के index वही होते हैं जिनको आपने argument के रूप में pass किया है।
- नयी table की cell values उसी column से आयेंगी जिसको आपने parameter के रूप में दिया था | इसका syntax निम्न है –

## `pandas.pivot(index, columns, values)`

- जहाँ index के द्वारा नए DataFrame का index बनता है जो table से लिया गया column name है।
- जहाँ columns के द्वारा नए DataFrame के columns बनते हैं जो table से लिए गए column name है।
- जहाँ values के द्वारा नए DataFrame की columns बनती हैं जो table से लिए गए column name की values हैं।

# pivot( ) method का प्रयोग करके Pivoting करना

syntax → pandas.pivot(index, columns, values)

- उदाहरण → DataFrame बनाना

```
import pandas as pd
ClassXII={ 'Name': ['Pratibha', 'Ritika', 'Saumya', 'Aryan'], \
           'Subject': ['CS', 'Phy', 'Chem', 'Maths'], \
           'Score': [99, 87, 88, 67], \
           'Grade': ['A1', 'A2', 'A2', 'B'] }
df=pd.DataFrame(ClassXII,columns=['Name', 'Subject', 'Score', 'Grade'])
```

	Name	Subject	Score	Grade
0	Pratibha	CS	99	A1
1	Ritika	Phy	87	A2
2	Saumya	Chem	88	A2
3	Aryan	Maths	67	B

- pivot table बनाना →

```
>>> pv=df.pivot(index='Name',columns='Subject',values='Score')
>>> pv
Subject      CS   Chem   Maths    Phy
Name
Aryan        NaN    NaN   67.0    NaN
Pratibha    99.0    NaN    NaN    NaN
Ritika       NaN    NaN    NaN  87.0
Saumya       NaN  88.0    NaN    NaN
```

हम इस pivot table में देख सकते हैं कि एक नयी table बनी है और Score column की values अलग अलग column में आयीं हैं। जबकि इसकी Name और Subject column, original table से match हो रही हैं जहाँ values match नहीं हो रही हैं उस जगह NaN (None) स्वतः ही चला गया है।

# pivot( ) method का प्रयोग .fillna( ) के साथ

syntax → pandas.pivot(index, columns, values).fillna()

- उदाहरण → DataFrame बनाना

```
import pandas as pd
ClassXII={ 'Name': ['Pratibha', 'Ritika', 'Saumya', 'Aryan'], \
           'Subject': ['CS', 'Phy', 'Chem', 'Maths'], \
           'Score': [99, 87, 88, 67], \
           'Grade': ['A1', 'A2', 'A2', 'B'] }
df=pd.DataFrame(ClassXII,columns=['Name', 'Subject', 'Score', 'Grade'])
```

>>> df				
	Name	Subject	Score	Grade
0	Pratibha	CS	99	A1
1	Ritika	Phy	87	A2
2	Saumya	Chem	88	A2
3	Aryan	Maths	67	B

- pivot table .fillna( ) के साथ बनाना बनाना →

```
>>> pv=df.pivot(index='Name',columns='Subject',values='Score').fillna(' ')
>>> pv
```

	CS	Chem	Maths	Phy
Name				
Aryan			67	
Pratibha	99			
Ritika			87	
Saumya		88		

हम इस pivot table में देख सकते हैं कि एक नयी table बनी है और Score column की values अलग अलग column में आयीं हैं। जबकि इसकी Name और Subject column, original table से match हो रही हैं। जहाँ values match नहीं हो रही हैं उस जगह NaN (None) भी नहीं आया बस रिक्त स्थान आगया है।

# Multiple columns के द्वारा pivoting करना

इसमें बस values parameter को हटा देते हैं।

syntax → pandas.pivot(index, columns)

- उदाहरण → DataFrame बनाना

```
import pandas as pd
ClassXII={ 'Name': ['Pratibha', 'Ritika', 'Saumya', 'Aryan'], \
           'Subject': ['CS', 'Phy', 'Chem', 'Maths'], \
           'Score': [99, 87, 88, 67], \
           'Grade': ['A1', 'A2', 'A2', 'B'] }
df=pd.DataFrame(ClassXII,columns=['Name', 'Subject', 'Score', 'Grade'])
```

	Name	Subject	Score	Grade
0	Pratibha	CS	99	A1
1	Ritika	Phy	87	A2
2	Saumya	Chem	88	A2
3	Aryan	Maths	67	B

- pivot table .fillna( ) के साथ बनाना बनाना →

```
>>> pv=df.pivot(index='Name',columns='Subject')
```

```
>>> pv
```

Subject	Score			Grade			
	CS	Chem	Maths	Phy	CS	Chem	Maths
Name							
Aryan	NaN	NaN	67.0	NaN	NaN	NaN	B
Pratibha	99.0	NaN	NaN	NaN	A1	NaN	NaN
Ritika	NaN	NaN	NaN	87.0	NaN	NaN	A2
Saumya	NaN	88.0	NaN	NaN	NaN	A2	NaN

# Multiple columns के द्वारा pivoting करना...

- पिछले उदहारण में हमने देखा कि कई index बन गए Subjects के और उनकी values भी एक बार Score के लिए और एक बार Grade के लिए प्रत्येक नाम के लिए दिखाई गयी हैं।
- इन्हें हम फ़िल्टर भी कर सकते हैं →

```
>>> pv.Score.fillna('')  
Subject      CS  Chem Maths  Phy  
Name  
Aryan          67  
Pratibha     99  
Ritika          87  
Saumya        88
```

```
>>> pv.Score.CS.fillna('')  
Name  
Aryan  
Pratibha      99  
Ritika  
Saumya  
Name: CS, dtype: object
```

```
>>> pv.Grade.CS.fillna('')  
Name  
Aryan  
Pratibha     A1  
Ritika  
Saumya  
Name: CS, dtype: object
```

```
>>> pv.Grade.Maths.fillna('')  
Name  
Aryan          B  
Pratibha  
Ritika  
Saumya  
Name: Maths, dtype: object
```

# Pivot Problem

- हमेशा ध्यान रखिये यदि index और columns के multiple values के साथ combination होंगे तो value error आयेगी।

```
import pandas as pd
ClassXII={ 'Name': ['Pratibha', 'Ritika', 'Saumya', 'Aryan', 'Pratibha'], \
           'Subject': ['CS', 'Phy', 'Chem', 'Maths', 'CS'], \
           'Score': [99, 87, 88, 67, 98], \
           'Grade': ['A1', 'A2', 'A2', 'B', 'A1'] }
df=pd.DataFrame(ClassXII,columns=['Name', 'Subject', 'Score', 'Grade'])
```

```
>>> df
      Name Subject Score Grade
0  Pratibha      CS    99    A1
1    Ritika      Phy    87    A2
2   Saumya     Chem    88    A2
3    Aryan     Maths    67     B
4  Pratibha      CS    98    A1
>>> pv=df.pivot(index='Name',columns='Subject',values='Score')
Traceback (most recent call last):
  File "<pyshell#18>", line 1, in <module>
    pv=df.pivot(index='Name',columns='Subject',values='Score')
  File "C:\Users\KVBBKServer\AppData\Local\Programs\Python\Python36\lib\site-packages\pandas\core\frame.py", line 5194, in pivot
    return pivot(self, index=index, columns=columns, values=values)
  File "C:\Users\KVBBKServer\AppData\Local\Programs\Python\Python36\lib\site-packages\pandas\core\reshape\reshape.py", line 415, in pivot
    return _index_and_stack(columns).dropna(axis=0, errors='raise'),
ValueError: Index contains duplicate entries, cannot reshape
```

# stack( ) और unstack( ) methods का प्रयोग

- stack( ) और unstack( ) methods दोनों DataFrame का layout पलट देते हैं अर्थात columns के सारे levels को row में और row के सारे levels को column में पलट देते हैं | DataFrame की **stacking** का मतलब है innermost column index को innermost row index की ओर ले जाना | और इसके उलटे क्रम को **unstacking** कहते हैं |

```
import pandas as pd
ClassXII={ 'Name': ['Pratibha', 'Ritika', 'Saumya', 'Aryan'], \
           'Subject': ['CS', 'Phy', 'Chem', 'Maths'], \
           'Score': [99, 87, 88, 67], \
           'Grade': ['A1', 'A2', 'A2', 'B'] }
df=pd.DataFrame(ClassXII,columns=['Name', 'Subject', 'Score', 'Grade'])
```

```
>>> pv=df.pivot(index='Name',columns='Subject')
>>> pv
      Score          Grade
      CS  Chem Maths   Phy   CS  Chem Maths   Phy
Name
Aryan    NaN    NaN  67.0  NaN    NaN    NaN     B  NaN
Pratibha 99.0  NaN    NaN  NaN    A1    NaN    NaN  NaN
Ritika    NaN    NaN  87.0  NaN    NaN    NaN    A2  NaN
Saumya    NaN  88.0  NaN  NaN    NaN    A2    NaN  NaN
```

## Stack Method का प्रयोग

```
>>> pv.stack()
      Score  Grade
      Name  Subject
      Aryan    Maths  67.0    B
      Pratibha  CS    99.0    A1
      Ritika    Phy    87.0    A2
      Saumya    Chem  88.0    A2
```

Stack Method का प्रयोग करने पर subjects जो horizontal में थे वो सभी vertical आगये | और यहाँ यह column breakdown में last level लेता है और इसे last row breakdown में बदल देता है

# stack( ) और unstack( ) methods का प्रयोग

```
import pandas as pd
ClassXII={ 'Name': ['Pratibha', 'Ritika', 'Saumya', 'Aryan'], \
           'Subject': ['CS', 'Phy', 'Chem', 'Maths'], \
           'Score': [99, 87, 88, 67], \
           'Grade': ['A1', 'A2', 'A2', 'B'] }
df=pd.DataFrame(ClassXII,columns=['Name', 'Subject', 'Score', 'Grade'])
```

```
>>> pv=df.pivot(index='Name',columns='Subject')
>>> pv
      Score          Grade
Subject   CS  Chem Maths    Phy   CS  Chem Maths    Phy
Name
Aryan     NaN  NaN  67.0    NaN  NaN  NaN       B  NaN
Pratibha  99.0 NaN  NaN    NaN  A1  NaN  NaN  NaN
Ritika    NaN  NaN  NaN    87.0  NaN  NaN  NaN  A2
Saumya    NaN  88.0 NaN  NaN  NaN  A2  NaN  NaN
```

```
>>> pv.stack()
      Score  Grade
Name   Subject
Aryan  Maths    67.0    B
Pratibha  CS     99.0   A1
Ritika   Phy     87.0   A2
Saumya  Chem    88.0   A2
```

```
>>> pv.stack().stack()
      Name      Subject
      Aryan      Maths  Score  67
                  Maths  Grade  B
      Pratibha  CS    Score  99
                  CS    Grade  A1
      Ritika    Phy   Score  87
                  Phy   Grade  A2
      Saumya    Chem  Score  88
                  Chem  Grade  A2
dtype: object
```

इस तरह से भी stack का प्रयोग किया जा सकता है जिसके stacking के बाद पुनः stacking की गयी है तो इसमें यह बचे हुए column level को भी move कर देता है।

# stack( ) और unstack( ) methods का प्रयोग

```
import pandas as pd
ClassXII=[{'Name': ['Pratibha', 'Ritika', 'Saumya', 'Aryan'], \
           'Subject': ['CS', 'Phy', 'Chem', 'Maths'], \
           'Score': [99, 87, 88, 67], \
           'Grade': ['A1', 'A2', 'A2', 'B']}]
df=pd.DataFrame(ClassXII,columns=['Name', 'Subject', 'Score', 'Grade'])
```

```
>>> pv=df.pivot(index='Name',columns='Subject')
>>> pv
      Score          Grade
      CS  Chem Maths   Phy   CS  Chem Maths   Phy
Subject
Name
Aryan    NaN    NaN  67.0    NaN    NaN    B    NaN
Pratibha 99.0    NaN    NaN    NaN    A1    NaN    NaN
Ritika    NaN    NaN    NaN  87.0    NaN    NaN    A2
Saumya    NaN  88.0    NaN    NaN    NaN    A2    NaN
```

```
>>> pv.stack(0).stack()
Name          Subject
Aryan        Grade  Maths    B
                  Score  Maths  67
Pratibha     Grade   CS    A1
                  Score   CS  99
Ritika       Grade   Phy    A2
                  Score   Phy  87
Saumya       Grade  Chem    A2
                  Score  Chem  88
dtype: object
```

```
>>> pv.stack(0)
      Subject
      CS  Chem Maths   Phy
Name
Aryan        Grade    NaN    NaN    B    NaN
                  Score    NaN    NaN  67    NaN
Pratibha     Grade    A1    NaN    NaN    NaN
                  Score    99    NaN    NaN    NaN
Ritika       Grade    NaN    NaN    NaN    A2
                  Score    NaN    NaN    NaN  87
Saumya       Grade    NaN    A2    NaN    NaN
                  Score    NaN  88    NaN    NaN
```

यह unstacking है

**Unstacking** भी stack के जैसे ही होती है बस उसमें एक argument '0' pass कर दिया जाता है।

# pivot\_table( ) method का प्रयोग करके Pivoting करना

- यह pivot( ) method का generalization है।
- जब आपके पास एक ही index या column के लिए duplicate values हों तो pivot\_table( ) method का प्रयोग किया जाता है।
- एक pivot table में counts, sums तथा table data से सम्बंधित अन्य functions भी उपलब्ध होते हैं।
- pivot\_table( ) method एक प्रकार से excel sheet जैसी ही DataFrame बनाती है।
- यह भी row को column में और column को row में बदलने के काम आता है।
- यह किसी भी data field की grouping को allow करता है।
- इसका syntax है →

```
pandas.pivot_table (DataFrame, values=None, index=None,  
                    columns=None, aggfunc='mean',  
                    fill_value=None, margins=False, dropna=True,  
                    margins_name='All')
```

- .pivot\_table() method में सारे arguments ज़रूरी नहीं हैं क्योंकि इसके अन्दर कुछ default values होती हैं।

# pivot\_table( ) method का प्रयोग करके Pivoting करना...

*pandas.pivot\_table (DataFrame, values=None, index=None, columns=None, aggfunc='mean', fill\_value=None, margins=False, dropna=True, margins\_name='All')*

- .pivot\_table() method में सारे arguments ज़रूरी नहीं हैं क्योंकि इसके अन्दर कुछ default values होती हैं।
- इसके syntax में -
  - DataFrame → एक pandas DataFrame है।
  - values → यह optional है और aggregate किये जाने वाला column है।
  - index → column, grouper, array, या list का नाम है।
  - columns → यह column, grouper, array, या list है।
  - aggfunc → aggregation function है।
  - fill\_value → इसके द्वारा हम default values सेट कर सकते हैं यदि values न दी गयीं हो।
  - margins → यह एक boolean होता है जिसका default false होता है, यदि हम इसे true कर देते हैं तो resulting dataframe में row और column का sum भी जुड़ जाता है।
  - dropna → यदि यह true है तो यह missing data वाली row को drop कर देता है।
  - margins\_name='All' → जब margins true हो तब total वाले row और column के नाम रखता है।

# pivot\_table( ) method का प्रयोग करके Pivoting करना ...

हम निम्न data को consider करके pivot table बनाते हैं →

```
import pandas as pd
ClassXII={ 'Name': ['Pratibha', 'Ritika', 'Saumya', 'Aryan', \
                    'Pratibha', 'Ritika', 'Saumya', 'Aryan', \
                    'Pratibha', 'Ritika', 'Saumya', 'Aryan', \
                    'Pratibha', 'Ritika', 'Saumya', 'Aryan'], \
                  'Test': ['Semester1', 'Semester1', 'Semester1', 'Semester1', \
                           'Semester1', 'Semester1', 'Semester1', 'Semester1', \
                           'Semester2', 'Semester2', 'Semester2', 'Semester2', \
                           'Semester2', 'Semester2', 'Semester2', 'Semester2'], \
                  'Subject': ['CS', 'CS', 'CS', 'CS', 'IP', 'IP', 'IP', \
                           'CS', 'CS', 'CS', 'CS', 'IP', 'IP', 'IP', 'IP'], \
                  'Marks': [99, 87, 88, 67, 98, 86, 88, 68, 97, 85, 89, 62, 94, 84, 81, 69] }
df=pd.DataFrame(ClassXII,columns=['Name', 'Test', 'Subject', 'Marks'])
```

>>> df	Name	Test	Subject	Marks
0	Pratibha	Semester1	CS	99
1	Ritika	Semester1	CS	87
2	Saumya	Semester1	CS	88
3	Aryan	Semester1	CS	67
4	Pratibha	Semester1	IP	98
5	Ritika	Semester1	IP	86
6	Saumya	Semester1	IP	88
7	Aryan	Semester1	IP	68
8	Pratibha	Semester2	CS	97
9	Ritika	Semester2	CS	85
10	Saumya	Semester2	CS	89
11	Aryan	Semester2	CS	62
12	Pratibha	Semester2	IP	94
13	Ritika	Semester2	IP	84
14	Saumya	Semester2	IP	81
15	Aryan	Semester2	IP	69

हम यह data CSV फाइल से भी ले सकते हैं।

```
>>> pv=df.pivot_table(index='Name',values='Marks',aggfunc='mean')
```

या

```
>>> pv=df.pivot_table(index='Name',aggfunc='mean')
>>> pv
```

Name	Marks
Aryan	66.5
Pratibha	97.0
Ritika	85.5
Saumya	86.5

# pivot\_table( ) method का प्रयोग करके Pivoting करना ...

pivot table को हम निम्न तरीके से भी बना सकते हैं →

```
>>> pd.pivot_table(df, index='Name', aggfunc='mean')  
          Marks  
Name  
Aryan      66.5  
Pratibha   97.0  
Ritika     85.5  
Saumya    86.5
```

```
>>> pv=df.pivot_table(index='Name', columns='Subject', aggfunc='mean')  
>>> pv  
          Marks  
Subject    CS      IP  
Name  
Aryan      64.5  68.5  
Pratibha   98.0  96.0  
Ritika     86.0  85.0  
Saumya    88.5  84.5
```

यहाँ aggfunc के values पर ध्यान दीजिये |

```
>>> pv=df.pivot_table(index='Name', columns='Subject', aggfunc='count')  
>>> pv  
          Marks      Test  
Subject    CS  IP    CS  IP  
Name  
Aryan      2   2     2   2  
Pratibha   2   2     2   2  
Ritika     2   2     2   2  
Saumya    2   2     2   2
```

# pivot\_table( ) method का प्रयोग करके Pivoting करना ...

आपके लिए एक exercise →

An Emp table contains the following data:

Empno	Name	Department	Salary	Commission	Job
100	Sunita Sharma	RESEARCH	45600	5600.0	CLERK
101	Ashok Singhal	SALES	43900	3900.0	SALESMAN
102	Sumit Avasti	SALES	27000	7000.0	SALESMAN
103	Jyoti Lamba	RESEARCH	45900	4900.0	MANAGER
104	Martin S.	SALES	32500	3500.0	SALESMAN
105	Binod Goel	SALES	45200	4200.0	MANAGER
106	Chetan Gupta	ACCOUNTS	36800	6800.0	MANAGER
107	Sudhir Rawat	RESEARCH	37000	7000.0	ANALYST
108	Kavita Sharma	ACCOUNTS	42900	4900.0	CLERK
109	Tushar Tiwari	SALES	49500	4500.0	MANAGER
110	Anand Rathi	OPERATIONS	41600	8200.0	SR. MANAGER
111	Sumit Vats	RESEARCH	47800	NaN	SR. MANAGER
112	Manoj Kaushik	OPERATIONS	43600	NaN	CLERK

- (a) Using above table create a DataFrame called dfE.
- (b) Display the department wise total salary.
- (c) Display the department wise average salary.
- (d) Display the department wise total and average salary.
- (e) Display the department wise maximum and minimum salary.
- (f) Display the department and job wise maximum salary.

# pivot\_table( ) method का प्रयोग करके Pivoting करना ...

Solution→

सबसे पहले आप दी गयी table का DataFrame बनायेंगे pandas का प्रयोग करके |

उसके बाद आपको निम्न function अप्लाई करने हैं -

(b) pd.pivot\_table(dfE, index='Department', values='Salary', aggfunc='sum')

(c) pd.pivot\_table(dfE, index='Department', values='Salary')

Or

pd.pivot\_table(dfE, index='Department', values='Salary', aggfunc='mean')

(d) pd.pivot\_table(dfE, index='Department', values='Salary', aggfunc=['sum', 'mean'])

(e) pd.pivot\_table(dfE, index='Department', values='Salary', aggfunc=['max', 'min'])

(f) pd.pivot\_table(dfE, index=['Department', 'Job'], values='Salary', aggfunc='max')

# DataFrames की Sorting

- DataFrame के data को भी row और column के values के आधार पर sort किया जा सकता है।
- By default sorting, row labels पर होती है वो भी बढ़ते हुए क्रम में।
- Pandas DataFrames के पास दो उपयोगी sort functions होते हैं →
  - sort\_values( ): यह function दिए गए column के data को ascending या descending आर्डर में sort करता है।
  - sort\_index( ): यह function rows (axis=0) या columns (axis=1) को sort करता है।
- इनका syntax निम्नवत है →
  - *DataFrame.sort\_values(by = None, axis=0, ascending = True, inplace = False)*
  - *DataFrame.sort\_index(by = None, axis=0, ascending = True, inplace = False)*
- यहाँ –
  - **by:** sort किया जाने वाला column
  - **axis:** यहाँ 0 pass करने का मतलब row wise और 1 का मतलब column wise
  - **ascending:** default में ascending true रहता है
  - **inplace:** default false होती है यदि आप नया dataframe नहीं चाहते हैं तो true pass करना होगा।

# DataFrames की Sorting...

<pre>&gt;&gt;&gt; df</pre> <table border="1"><thead><tr><th></th><th>Name</th><th>Subject</th><th>Marks</th><th>Grade</th></tr></thead><tbody><tr><td>0</td><td>Pratibha</td><td>CS</td><td>99</td><td>A+</td></tr><tr><td>1</td><td>Ritika</td><td>IP</td><td>87</td><td>A</td></tr><tr><td>2</td><td>Saumya</td><td>PHY</td><td>88</td><td>B+</td></tr><tr><td>3</td><td>Aryan</td><td>CHEM</td><td>67</td><td>B</td></tr></tbody></table> <p>यहाँ by default ascending आर्डर में sort हुआ है।</p> <p>Descending आर्डर में sort करने के लिए निम्न उदाहरण है।</p>		Name	Subject	Marks	Grade	0	Pratibha	CS	99	A+	1	Ritika	IP	87	A	2	Saumya	PHY	88	B+	3	Aryan	CHEM	67	B	<pre>&gt;&gt;&gt; dfn=df.sort_values('Name')</pre> <p>या</p> <pre>&gt;&gt;&gt; dfn=df.sort_values(by='Name')</pre> <pre>&gt;&gt;&gt; dfn</pre> <table border="1"><thead><tr><th></th><th>Name</th><th>Subject</th><th>Marks</th><th>Grade</th></tr></thead><tbody><tr><td>3</td><td>Aryan</td><td>CHEM</td><td>67</td><td>B</td></tr><tr><td>0</td><td>Pratibha</td><td>CS</td><td>99</td><td>A+</td></tr><tr><td>1</td><td>Ritika</td><td>IP</td><td>87</td><td>A</td></tr><tr><td>2</td><td>Saumya</td><td>PHY</td><td>88</td><td>B+</td></tr></tbody></table>		Name	Subject	Marks	Grade	3	Aryan	CHEM	67	B	0	Pratibha	CS	99	A+	1	Ritika	IP	87	A	2	Saumya	PHY	88	B+
	Name	Subject	Marks	Grade																																															
0	Pratibha	CS	99	A+																																															
1	Ritika	IP	87	A																																															
2	Saumya	PHY	88	B+																																															
3	Aryan	CHEM	67	B																																															
	Name	Subject	Marks	Grade																																															
3	Aryan	CHEM	67	B																																															
0	Pratibha	CS	99	A+																																															
1	Ritika	IP	87	A																																															
2	Saumya	PHY	88	B+																																															
<pre>&gt;&gt;&gt; dfn=df.sort_values(by='Name', ascending=False)</pre> <pre>&gt;&gt;&gt; dfn</pre> <table border="1"><thead><tr><th></th><th>Name</th><th>Subject</th><th>Marks</th><th>Grade</th></tr></thead><tbody><tr><td>2</td><td>Saumya</td><td>PHY</td><td>88</td><td>B+</td></tr><tr><td>1</td><td>Ritika</td><td>IP</td><td>87</td><td>A</td></tr><tr><td>0</td><td>Pratibha</td><td>CS</td><td>99</td><td>A+</td></tr><tr><td>3</td><td>Aryan</td><td>CHEM</td><td>67</td><td>B</td></tr></tbody></table>		Name	Subject	Marks	Grade	2	Saumya	PHY	88	B+	1	Ritika	IP	87	A	0	Pratibha	CS	99	A+	3	Aryan	CHEM	67	B	<p>↑</p> <p>Ascending parameter की वैल्यू False pass कर दी है।</p>																									
	Name	Subject	Marks	Grade																																															
2	Saumya	PHY	88	B+																																															
1	Ritika	IP	87	A																																															
0	Pratibha	CS	99	A+																																															
3	Aryan	CHEM	67	B																																															
<pre>&gt;&gt;&gt; dfn=df.sort_values(['Name', 'Marks'], ascending=True)</pre> <pre>&gt;&gt;&gt; dfn</pre> <table border="1"><thead><tr><th></th><th>Name</th><th>Subject</th><th>Marks</th><th>Grade</th></tr></thead><tbody><tr><td>3</td><td>Aryan</td><td>CHEM</td><td>67</td><td>B</td></tr><tr><td>0</td><td>Pratibha</td><td>CS</td><td>99</td><td>A+</td></tr><tr><td>1</td><td>Ritika</td><td>IP</td><td>87</td><td>A</td></tr><tr><td>2</td><td>Saumya</td><td>PHY</td><td>88</td><td>B+</td></tr></tbody></table>		Name	Subject	Marks	Grade	3	Aryan	CHEM	67	B	0	Pratibha	CS	99	A+	1	Ritika	IP	87	A	2	Saumya	PHY	88	B+	<p>यहाँ यदि हम दो column इस प्रकार से देते हैं तो multiple columns पर sorting apply हो जाती है।</p>																									
	Name	Subject	Marks	Grade																																															
3	Aryan	CHEM	67	B																																															
0	Pratibha	CS	99	A+																																															
1	Ritika	IP	87	A																																															
2	Saumya	PHY	88	B+																																															

# Sort by index

```
>>> dfn=df.sort_index()
```

```
>>> dfn
```

	Name	Subject	Marks	Grade
0	Pratibha	CS	99	A+
1	Ritika	IP	87	A
2	Saumya	PHY	88	B+
3	Aryan	CHEM	67	B

यहाँ यह ascending आर्डर में sorting है।

```
>>> dfn=df.sort_index(ascending=False)
```

```
>>> dfn
```

	Name	Subject	Marks	Grade
3	Aryan	CHEM	67	B
2	Saumya	PHY	88	B+
1	Ritika	IP	87	A
0	Pratibha	CS	99	A+

यहाँ यह descending आर्डर में sorting है।

## याद रखने योग्य बातें:

1. pivot( ) method एक नयी table बनाता है जिनके row और column unique होते हैं।
2. pivot( ) method का उपयोग aggregation के बिना pivot के लिए किया जाता है।
3. **stacking** का मतलब है innermost column index को innermost row index की ओर ले जाना।

- कृपया हमारे ब्लॉग को फॉलो करिए और youtube channel को subscribe करिए | ताकि आपको और सारे chapters मिल सकें |

[www.pythontrends.wordpress.com](http://www.pythontrends.wordpress.com)

## एक शुरुआत pythontrends

पाइथन सीखें और सिखाएं

मुख्य पृष्ठ/Home

संपर्क/Contact

कक्षा-11 आई० पी० /Class -XI IP ▾

कक्षा-11 कंप्यूटर साइंस/Class - XI Computer Science


कक्षा-12 कंप्यूटर साइंस/Class- 12 CS

पाइथन प्रोग्राम और SQL कनेक्टिविटी / Python Program and SQL connectivity

कार्य/Assignments

पाठ्यक्रम(CS और IP)/syllabus(CS and IP)

नमस्ते दोस्तों ! /Hello Friends!



यह ब्लॉग उन बच्चों की मदद के लिए बनाया गया है जो python में प्रोग्रामिंग सीख रहे हैं |  
यह ब्लॉग द्विभाषीय होगा जिससे सीबीएसई बोर्ड के वे बच्चे जिहें अंग्रजी भाषा में समस्या होती है उन्हें सही मार्गदर्शन करेगा तथा प्रोग्रामिंग में उनकी सहायता करेगा | जैसा की हम जानते हैं की हमारे देश में कई क्षेत्र और कई लोग ऐसे हैं जिनकी अंग्रेज़ी उतनी मज़बूत नहीं है क्यों कि ये हमारी मातृभाषा नहीं है | तो हमें कभी कभी अंग्रेज़ी के कठिन शब्दों को समझने में समय लगता है और ये समय अगर लॉजिकल विचारों में लगे तो छात्रों का अधिक भला हो सकता है |  
इस ब्लॉग पर हम कोशिश करेंगे की पाइथन से सम्बंधित सभी तथ्य तथा सामग्री इस ब्लॉग पर उपलब्ध कराएं | यह ब्लॉग संजीव भदौरिया (पी जी टी कंप्यूटर साइंस) के० वि० बाराबंकी लखनऊ संभाग एवं नेहा त्यागी (पी जी टी कंप्यूटर साइंस) के० वि० क्र -5 जयपुर,